

CENTRE HOSPITALIER SAINT-AURÉLIEN (CHSA)

Rapport technique et recommandations stratégiques

Proof of Concept d'un agent IA de triage médical

Auteur : **Guedj, Daniel** — IA Engineer junior

Mission : spécialisation d'un modèle de langage (SFT + LoRA, alignement DPO)

Août 2026

Avertissement : le système décrit est un outil d'aide à la décision destiné au personnel soignant. Il ne pose pas de diagnostic et ne remplace pas un professionnel de santé.

Sommaire

- Résumé exécutif
- 1. Contexte et objectifs
- 2. Méthodologie — Préparation des données
- 3. Méthodologie — Entraînement (SFT LoRA, DPO)
- 4. Résultats et métriques de performance
- 5. Analyse des résultats (forces et faiblesses)
- 6. Démarche qualité — itérations de diagnostic
- 7. Architecture, traçabilité et déploiement
- 8. Limites connues
- 9. Roadmap de passage à l'échelle
- 10. Conclusion
- Annexes

Résumé exécutif

Face à la surcharge de son service des urgences, le CHSA a commandé un Proof of Concept (POC) d'agent IA d'aide au triage. Ce rapport présente la réalisation complète, de la préparation des données au déploiement d'un endpoint, en passant par le post-training d'un modèle de langage compact.

Ce qui a été livré : un dataset médical bilingue (français/anglais) anonymisé et versionné (5 000 paires pour le fine-tuning supervisé, 3 000 paires de préférences pour l'alignement) ; un modèle **Qwen3-1.7B** spécialisé par SFT + LoRA puis aligné par DPO ; une évaluation clinique orientée sécurité ; une API de déploiement (FastAPI) conteneurisée (Docker) ; un pipeline d'intégration continue (GitHub Actions) ; et un endpoint public déployé gratuitement sur GPU (Hugging Face ZeroGPU).

Principaux résultats : la chaîne de bout en bout est fonctionnelle et reproductible. L'alignement DPO améliore les métriques de sécurité les plus importantes — meilleure détection des cas vitaux (de 0,33 à 0,50) et des signes d'alerte (de 0,04 à 0,19), moins de réponses à risque — sans améliorer l'exactitude brute. Le modèle répond de façon pertinente en anglais ; sa qualité en français est plus faible, une limite mesurée et expliquée par la composition des données.

Conclusion : le POC démontre la faisabilité technique et la valeur clinique potentielle. Une roadmap de passage à l'échelle est proposée (données françaises rédigées, annotations cliniques, modèles plus grands, inférence vLLM).

1. Contexte et objectifs

Le service des urgences du CHSA connaît une surcharge constante, avec un risque de retard de prise en charge des cas critiques. L'objectif du POC est de valider qu'un modèle de langage spécialisé peut assister le personnel soignant dans le triage initial : collecter des symptômes, évaluer un niveau de priorité, et fournir des explications, tout en garantissant la conformité RGPD et la traçabilité des interactions.

Stratégie en trois phases

- **Phase 1 — Validation conceptuelle** : modèle compact Qwen3-1.7B-Base pour valider rapidement les hypothèses techniques (objet de ce POC).
- **Phase 2 — Optimisation ciblée** : fine-tuning supervisé (SFT) avec LoRA, puis alignement par préférences (DPO).
- **Phase 3 — Projection industrielle** : modèles plus grands (32B+) et jeux de données étendus pour la production.

Principe directeur : sécurité et robustesse

Deux exigences transverses structurent l'ensemble : (1) une **traçabilité auditable** de chaque étape et interaction ; (2) une **robustesse « fallback-first »** — chaque dépendance externe dispose d'un repli gracieux pour qu'une démonstration ne tombe jamais en panne. Le système est positionné comme une aide à la décision, jamais comme un outil de diagnostic autonome.

2. Méthodologie — Préparation des données

2.1 Sources et licences

Quatre corpus publics ont été agrégés. Leur normalisation précoce vers un schéma canonique unique découple le projet des formats amont et des versions de librairies.

Source	Langue	Type	Licence	Usage
MedQuAD	EN	Q/R	NIH/NLM	SFT
FrenchMedMCQA	FR	QCM	Apache-2.0	SFT
MedMCQA	EN	QCM	Voir carte	SFT
UltraMedical-Preference	EN	Préférences	MIT	DPO (+ SFT via 'chosen')

Tableau 1 — Corpus sources. Le créneau « MediQA » du brief, ambigu, a été câblé sur MedMCQA (QCM anglophone de raisonnement clinique).

2.2 Dataset de fine-tuning supervisé (SFT)

Le dataset SFT vise 5 000 paires instruction-réponse, au format conversationnel (messages system/user/assistant), directement exploitable par la librairie TRL. Chaque exemple est encadré par un prompt système de triage prudent (réponse exacte, signalement des signes d'alerte, renvoi au clinicien).

Indicateur	Valeur
Paires finales	5 000
Répartition par source	1 250 par source (équilibre round-robin)
Répartition par langue	3 750 EN / 1 250 FR
Doublons retirés (déduplication)	51 235
Exemples rejetés (qualité)	506
Part de QCM plafonnée	30 % (comportement de réponse rédigée)

Tableau 2 — Composition du dataset SFT.

La déduplication a retiré plus de 51 000 questions répétées présentes dans les corpus bruts : sans elle, ces items auraient été sur-représentés et auraient créé des fuites triviales. La part de QCM a été plafonnée à 30 % pour que le modèle apprenne à répondre en prose plutôt qu'à générer des questions à choix multiples.

2.3 Dataset d'alignement (DPO)

Le dataset de préférences (paires « chosen » / « rejetée ») provient d'UltraMedical-Preference. Des contrôles de cohérence écartent les paires identiques ou incomplètes.

Indicateur	Valeur
Paires finales	3 000 (toutes anglophones)
Lignes brutes traitées	109 353
Doublons retirés	12 438
Rejets (longueur/cohérence)	12

Tableau 3 — Composition du dataset DPO.

2.4 Anonymisation et conformité RGPD

L'anonymisation s'appuie sur Microsoft Presidio (détection NER multilingue via spaCy) avec un filet de sécurité par expressions régulières. Un contrôle qualité re-scanner les sorties et garantit **zéro PII structurée résiduelle** (e-mail, téléphone, IBAN).

Un arbitrage explicite **utilité** ↔ **confidentialité** a été formalisé : le masquage NER agressif (noms, lieux, dates) génère de nombreux faux positifs sur le vocabulaire médical et dégrade le modèle, sans bénéfice réel sur des corpus publics déjà dé-identifiés. Deux modes coexistent donc : un mode « **training** » (PII structurées seulement, pour l'entraînement) et un mode « **full** » (masquage complet, destiné aux vraies données patients en production, avec réalisation préalable d'une AIPD).

2.5 Découpage, évaluation clinique et versionnement

- **Splits train/val/test** stratifiés (source, langue), avec un contrôle **anti-fuite conscient des groupes** garantissant qu'une même question ne peut apparaître à la fois en entraînement et en évaluation.
- **Jeu d'évaluation clinique séparé** : 18 scénarios bilingues rédigés indépendamment, équilibrés (6 par niveau de priorité ; 10 FR / 8 EN).
- **Schéma de métadonnées** de triage (symptômes, antécédents, constantes vitales, priorité, confiance) formalisé et validé.
- **Versionnement** reproductible par empreintes SHA-256 (manifeste + carte dataset), sans dépendance externe.

Jeu	Train	Validation	Test	Anti-fuite
SFT	4 500	248	252	OK (0 chevauchement)
DPO	2 700	150	150	OK (0 chevauchement)

Tableau 4 — Découpage des jeux de données.

3. Méthodologie — Entraînement

3.1 Fine-tuning supervisé (SFT + LoRA)

Le modèle Qwen3-1.7B-Base est spécialisé par SFT avec LoRA (adaptation de faible rang), ce qui limite l'empreinte GPU. Un mécanisme de profils auto-détecte la VRAM disponible et adapte les hyperparamètres ; l'entraînement a été mené sur une NVIDIA RTX 3060 (12 Go).

Paramètre	Valeur
Modèle de base	Qwen/Qwen3-1.7B-Base (Apache-2.0)
Méthode	LoRA (r=16, alpha=32, dropout=0,05) en bf16
Profil matériel	« mid » (batch 2 x accumulation 8, séquence 2048)
Époques / pas	3 époques — 846 pas
Durée	~1 h 09 (RTX 3060, 12 Go)
Taux d'apprentissage	2e-4 (cosine, warmup)

Tableau 5 — Configuration du SFT.

3.2 Alignement par préférences (DPO)

Le modèle SFT est ensuite aligné par DPO (Direct Preference Optimization). L'adaptateur SFT est fusionné dans les poids pour servir de politique de départ, puis un nouvel adaptateur LoRA est entraîné sur les paires de préférences. Le modèle de référence est le même modèle avec l'adaptateur désactivé — approche économe en mémoire.

Paramètre	Valeur
Base	Modèle SFT fusionné
beta (DPO)	0,1
Taux d'apprentissage	5e-6
Époques	1
Signal d'apprentissage (validation smoke)	rewards/accuracies = 0,69 ; marge = +0,066

Tableau 6 — Configuration du DPO. La marge positive confirme que le modèle apprend bien à préférer les bonnes réponses.

3.3 Reproductibilité et traçabilité

Chaque étape (ingestion, anonymisation, découpage, entraînement, évaluation) émet un événement dans un **journal d'audit inviolable** : chaque enregistrement est chaîné au précédent par un hachage SHA-256, si bien que toute modification a posteriori est détectée et localisée. Graine aléatoire fixée, checkpoints et reprise d'entraînement assurent la reproductibilité.

4. Résultats et métriques de performance

4.1 Comparaison SFT vs SFT+DPO (jeu clinique, 18 scénarios)

Les deux modèles ont été évalués sur le jeu clinique séparé, via le même harnais et un module d'inférence propre (décodage glouton, anti-répétition, gestion de l'EOS).

Métrique	SFT	SFT+DPO	Tendance
Exactitude de priorité (globale)	0,389	0,389	=
Détection urgence vitale	0,333	0,500	amélioration
Détection urgent	0,833	0,667	baisse
Détection non urgent	0,000	0,000	=
Rappel des signes d'alerte	0,042	0,194	amélioration (x4,6)
Réponses avec drapeau de sécurité	3	1	amélioration
Réponses non exploitables	3	4	stable

Tableau 7 — Métriques comparées (empilement SFT+DPO correct après fusion des adaptateurs).

4.2 Latence

Configuration	Latence observée	Commentaire
API locale (backend de repli)	~196 ms	Réponse rule-based (filet de sécurité)
Modèle réel — HF ZeroGPU	~6,4 s	Premier appel, attachement GPU à froid inclus

Tableau 8 — Mesures de latence. En production, vLLM (batching continu) réduirait fortement la latence par requête et augmenterait le débit.

5. Analyse des résultats (forces et faiblesses)

Ce que le DPO apporte

L'alignement DPO n'améliore pas l'exactitude brute mais déplace le modèle vers un comportement **plus sûr**, ce qui est précisément son objet : meilleure détection des cas vitaux, bien meilleur repérage des signes d'alerte, et diminution des réponses à risque. Le compromis observé est une baisse sur les cas « urgent », le modèle ayant tendance à les sur-classer en « urgence vitale » — une direction prudente en contexte de triage.

Forces

- Chaîne complète, reproductible et testée (donnée → modèle → évaluation → déploiement).
- Comportement pertinent et sûr en anglais ; escalade fiable sur les cas critiques.
- Sur-triage plutôt que sous-triage : erreur du « bon côté » pour la sécurité patient.
- Traçabilité et conformité RGPD intégrées dès la conception.

Faiblesses

- **Qualité moindre en français** : les sources rédigées sont anglophones ; la seule source française est du QCM. Le modèle retombe parfois en format QCM en français.
- **Sur-triage systématique** (les cas non urgents ne sont pas identifiés comme tels).
- **Petit modèle (1,7B)** et jeu d'évaluation restreint (18 scénarios) : les écarts sont des tendances, non des preuves statistiques.
- Métriques automatiques approximatives : une validation clinique humaine reste nécessaire.

6. Démarche qualité — itérations de diagnostic

La rigueur méthodologique s'illustre par une série de problèmes détectés, diagnostiqués à la racine, corrigés, puis verrouillés par un test automatique. La suite compte 53 tests.

#	Problème observé	Cause racine	Correctif
1	Fuite entre train et test	Doublons recréés par l'anonymisation	Découpage conscient des groupes
2	Modèle générant « <PERSON> » en boucle	Sur-masquage NER de termes médicaux	Mode d'anonymisation « training »
3	Réponses en format QCM	50 % du dataset était du QCM	Plafonnement du QCM à 30 %
4	Caractères parasites / bouclage	Modèle base + échantillonnage	Décodage glouton + anti-répétition
5	Faux positif d'un test (VRAM)	Test non portable (supposait aucun GPU)	Test rendu agnostique
6	Faux positif du contrôle sécurité	Liste de mots d'escalade trop littérale	Élargissement des synonymes
7	DPO chargé de façon incomplète	Adaptateur DPO sur base brute (SFT perdu)	Fusion correcte des adaptateurs

#	Problème observé	Cause racine	Correctif
8	Conteneur qui ne démarre pas	Fichier de lancement non copié dans l'image	Lancement direct d'uvicorn

Tableau 9 — Itérations de diagnostic (un défaut CI supplémentaire, lié à une dépendance de test, a également été corrigé).

7. Architecture, traçabilité et déploiement

7.1 API et robustesse

Un endpoint FastAPI expose /health et /triage. Le module d'inférence est partagé entre l'évaluation et l'API. En l'absence de modèle (pas de GPU ou poids indisponibles), l'API bascule sur un **repli rule-based** prudent : elle répond toujours. Chaque appel est tracé (métadonnées uniquement, jamais le texte patient brut).

7.2 Conteneurisation et intégration continue

- **Docker** : image de l'API avec healthcheck ; compatible avec les plateformes imposant la variable PORT (Render, Cloud Run).
- **CI/CD (GitHub Actions)** : à chaque push, exécution des 53 tests puis construction de l'image et test de démarrage du conteneur.

7.3 Déploiement cloud

L'endpoint de démonstration est déployé gratuitement sur **Hugging Face ZeroGPU** (GPU H200 à la demande), servant le vrai modèle SFT+DPO :

URL publique : <https://huggingface.co/spaces/DagueGG/chsa-triage-dpo>

Modèle publié : <https://huggingface.co/DagueGG/chsa-triage-dpo>

Pour la production, une procédure **vLLM** (inférence rapide, batching continu, API compatible OpenAI) est documentée : l'API FastAPI sert alors de façade stable devant un backend d'inférence remplaçable.

8. Limites connues

- Performance en français à renforcer (couverture de données déséquilibrée).
- Sur-triage : les cas non urgents ne sont pas encore correctement identifiés.
- Modèle compact (1,7B) : pertinence et robustesse limitées par rapport à un grand modèle.
- Jeu d'évaluation restreint et métriques automatiques : validation clinique humaine indispensable avant tout usage réel.
- Aucune donnée patient réelle utilisée : une AIPD (analyse d'impact) complète est requise avant tout traitement de données identifiantes en production.

9. Roadmap de passage à l'échelle

Axe	Action recommandée
Données françaises	Ajouter des Q/R FR rédigées (traduction ciblée de MedQuAD, source FR en prose) pour corriger la faiblesse linguistique.
Étiquetage clinique	Constituer, avec des cliniciens, un jeu annoté en niveaux de priorité et signes d'alerte (données de triage réelles).
Modèle	Passer à un modèle plus grand (32B+) une fois le POC validé (phase 3).
Anonymisation	Modèle NER médical dédié + allow-list de termes cliniques.

Axe	Action recommandée
Inférence	Déploiement vLLM sur GPU pour la latence et le débit en production.
Évaluation	Élargir le jeu clinique et introduire une évaluation humaine continue.
Gouvernance	AIPD, supervision post-déploiement, checklist go/no-go, revue clinique.

Tableau 10 — Recommandations stratégiques pour la mise à l'échelle.

10. Conclusion

Le POC atteint son objectif : démontrer, de bout en bout, la faisabilité technique et la valeur clinique potentielle d'un agent d'aide au triage. La chaîne complète — dataset bilingue anonymisé et versionné, modèle Qwen3-1.7B spécialisé (SFT+LoRA puis DPO), évaluation clinique orientée sécurité, API conteneurisée, CI/CD et endpoint déployé — est fonctionnelle, reproductible et tracée.

La démarche a privilégié la rigueur : chaque difficulté a été diagnostiquée à la racine et verrouillée par un test, et les décisions techniques ont été documentées. Les limites (français, sur-triage, taille du modèle) sont mesurées et assorties d'une roadmap claire. Le système est prêt à évoluer vers une phase d'optimisation ciblée, sous supervision clinique et dans un cadre RGPD renforcé.

Annexes

A. Décisions d'architecture (ADR)

- ADR-0001 Stack et stratégie de repli — ADR-0002 Ingestion et versions de librairies
- ADR-0003 Dataset SFT — ADR-0004 Dataset DPO — ADR-0005 Anonymisation RGPD
- ADR-0006 Splits, éval clinique, métadonnées, versionnement
- ADR-0007 SFT LoRA — ADR-0008 Évaluation et sécurité — ADR-0009 DPO
- ADR-0010 API FastAPI — ADR-0011 Docker et CI/CD — ADR-0012 Déploiement cloud

B. Indicateurs qualité du projet

Indicateur	Valeur
Tests automatisés	53 (verts en CI)
Décisions d'architecture documentées (ADR)	12
Traçabilité	Journal d'audit à chaîne de hachage SHA-256
Endpoint public	Hugging Face ZeroGPU (modèle réel)

Tableau 11 — Synthèse qualité.

C. Ressources

- Modèle de base : Qwen/Qwen3-1.7B-Base (Apache-2.0).
- Sources : MedQuAD, FrenchMedMCQA (Apache-2.0), MedMCQA, UltraMedical-Preference (MIT).
- Outils : Hugging Face Transformers / TRL / PEFT, Presidio, FastAPI, Docker, GitHub Actions, vLLM.